Cas d’étude
Jeux olympiques 1896-2022



Les données utilisées pour former l’ensemble utilisé dans le cas d’études proviennent de deux jeux de données Kaggle :

- Olympedia
- Tweets Tokyo 2020

Olympedia

Description

Source :
https://www.kaggle.com/datasets/josephcheng123456/olympic-historical-dataset-from-olympediaorg
Dernier accès : Septembre 2024

Le jeu de données d'origine est composé de 6 fichiers .csv :
- Olympic_Athlete_Bio.csv
- Olympic_Athlete_Event_Results.csv
- Olympic_Games_medal_Tally.csv
- Olympic_Results.csv
- Olympics_Country.csv
- Olympic_Games.csv

Les données sont scrappées du site http://www.olympedia.org/. La période couverte va des jeux d'été d'Athènes en 1896 à ceux de Pékin 2022 (Hiver).

Les deux paragraphes suivants donnent la description du dataset telle que fournie sous Kaggle.

Basic Dataset Information

This dataset contains:

- **154,902** unique athletes and their biological information, i.e., height, weight, date of birth
- **All Winter / Summer Olympic** games from **1896 to 2022**
- **7326** unique results (result for a specific event played at an Olympic game)
- **314,726** rows of athlete to result data which includes both team sports and individual sports
    - each row includes position - which is how well the athlete performed for the specific event (Ranked)
        - Note: not all position is integer - contains strings which contains information on which round / heat they achieved
- **235** distinct countries (some existing from the past)

How to Use the Dataset for a complete athlete-event dataset

- **Olympic_Athlete_Event_Results.csv** - Contains basic athlete to result data (including athlete_id and result_id)
- LEFT JOIN **Olympic_Athlete_Event_Results.csv** file with **Olympic_Athlete_Bio.csv** (on athlete_id) for complete information of the athlete (i.e., height, weight, date of birth when participating in the event)
- LEFT JOIN **Olympic_Athlete_Event_Results.csv** with **Olympic_Results.csv** (on result_id) to obtain detailed information about the result (i.e., start date, sport, result_participants, format, time
- Aggregate information to obtain features such as:
    - **BMI** - from height and weight
    - **Age of participation** - start date of the result subtract the date of birth of the athlete

Modifications effectuées – Informations importantes

Ces fichiers d'origine ont été modifiés pour enlever certains bugs et certaines difficultés.

Quelques informations complémentaires qui vous feront gagner du temps :

- Tous les athlètes du fichier Olympic_Athlete_Event_Result n'ont pas forcément de bio (c'est-à-dire qu'ils ne sont pas forcément présents dans le fichier Olympic_Athlete_Bio)
- Le nom des athlètes peut changer au fur et à mesure des éditions (plusieurs noms d'athlètes différents pour un même athlete_id dans le fichier Olympic_Athlete_Event_Result). Pour la mise en place du projet, un seul nom suffira.
- Un athlète peut concourir pour un pays dans lequel il n'est pas né

Tweets Tokyo 2020

Description

Source :
https://www.kaggle.com/datasets/gpreda/tokyo-olympics-2020-tweets
Dernier accès : Septembre 2024

Le jeu de données est composé d'un seul fichier :
tokyo_2020_tweets.csv

Les données ont été récupérées via l'API Twitter en 2021. Elles concernent exclusivement les jeux de Tokyo 2020 (2021).

Il y a 160549 tweets. Les champs les plus importants pour les analyses à venir sont les suivants : chaque tweet possède un identifiant unique (id), un texte (text) et la liste de ses hashtags (hashtags).